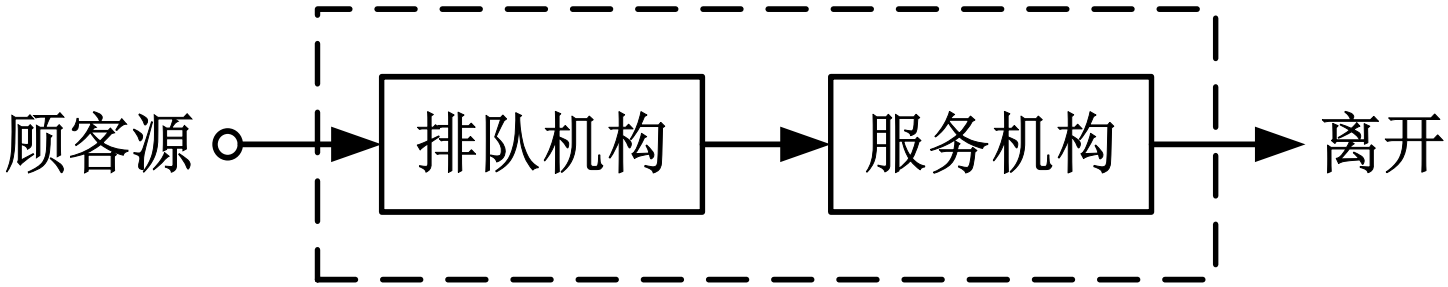
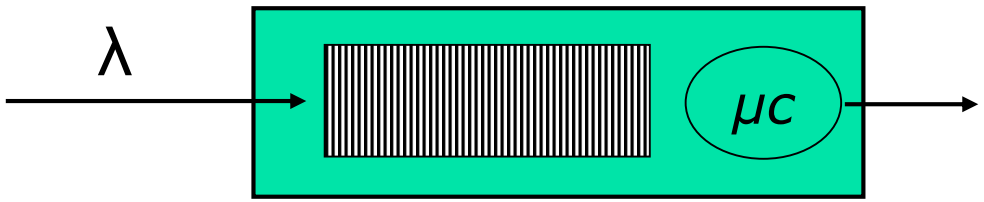
1．排队论基础

排队论研究的是顾客随机到达一个服务系统、排队等待、被服务并离开的过程。



计算机网络上的数据传输也与此类似



1．排队论基础 —— 泊松（Poisson）过程

（1）若假定有无穷多个报文，且报文是相互独立地到达，则在一定时间间隔t内正好有k个报文到达的概率服从Poisson分布：

$$P_k(t) = = \frac{(\lambda t)^k}{k!} \cdot e^{-\lambda t}$$

其中 λ——报文的平均到达率（msg/s） （每秒到达的报文数）

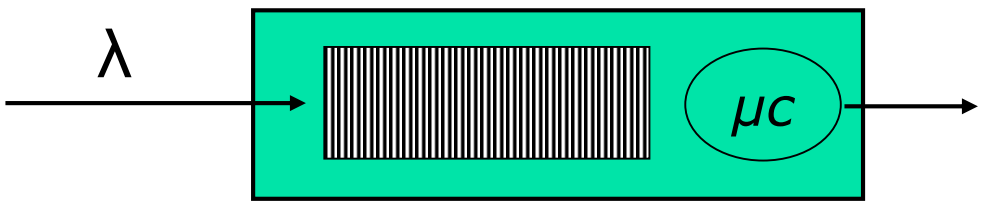
k = 0，1，2，…

如： k=0, $P_0(t) = e^{-\lambda t}$ k=1, $P_1(t) = \lambda t \cdot e^{-\lambda t}$

相邻两报文到达的时间间隔t的概率密度函数—a(t)

$a(t) = \lambda e^{-\lambda t}$

$b(t) = \mu c e^{-\mu c t}$



服务（发送）时间的概率密度函数—b(t)

（2） 相邻两报文到达的时间间隔t的概率密度函数—a(t)

概率密度函数表征随机事件发生的可能性（概率）与随机变量之间的关系，可能性越大，该t对应的事件发生的概率密度越大，也就是事件越容易发生。

t：连续随机变量，表示相邻两个报文到达的时间间隔。

事件A：t时间间隔内无报文到达，t+△t内有一个报文到达。

$$P_A[t, t+\Delta t] = \int_t^{t+\Delta t} a(t)dt \approx a(t)\Delta t$$

根据泊松公式：

$$P_0(t) = e^{-\lambda t}$$

$$P_1(\Delta t) = \lambda \Delta t \cdot e^{-\lambda \Delta t}$$

而：

$$P_A[t, t+\Delta t] = P_0(t) \cap P_1(\Delta t)$$

所以：

$$a(t)\Delta t = e^{-\lambda t} \cdot \lambda \Delta t \cdot e^{-\lambda \Delta t}$$

$$a(t) = e^{-\lambda t} \cdot \lambda \cdot e^{-\lambda \Delta t}$$

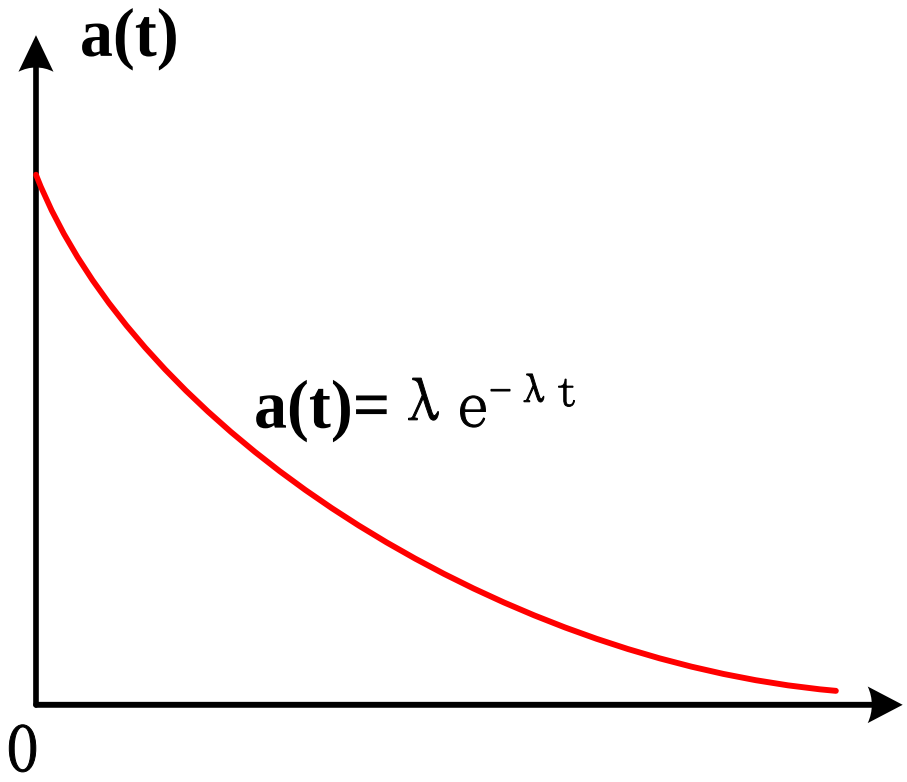
当$\Delta t \to 0$时：

$$a(t) = \lambda e^{-\lambda t}$$

——呈负指数关系

时间间隔t内事件A（有一个报文到达）发生的可能性与t的关系——**相邻两报文到达的时间间隔为t的概率密度函数**

1．排队论基础 —— 泊松（Poisson）过程



均值：$E_t = \int_0^{\infty} t \cdot a(t) dt = \frac{1}{\lambda}$

方差：$\sigma_t^2 = \frac{1}{\lambda^2}$

均方差：$\sigma_t = \frac{1}{\lambda}$

注意：t是相邻两个报文到达的时间间隔。

结论：短的到达时间间隔比长的时间间隔出现的更为频繁。

这与计算机通信中的数据流的特点相吻和：突发性、间歇性

（3） 服务（发送）时间的概率密度函数——b(t)

$$b(t) = \mu c e^{-\mu c t}$$

其中，c ——数据的发送速率（信道容量） (bits/s)

1/μ—— 报文的平均长度（bit/msg)

报文发送速率：$\lambda = \mu c$ （msg/s）

均值：$E_t = \frac{1}{\mu c}$ ——报文的平均发送时间

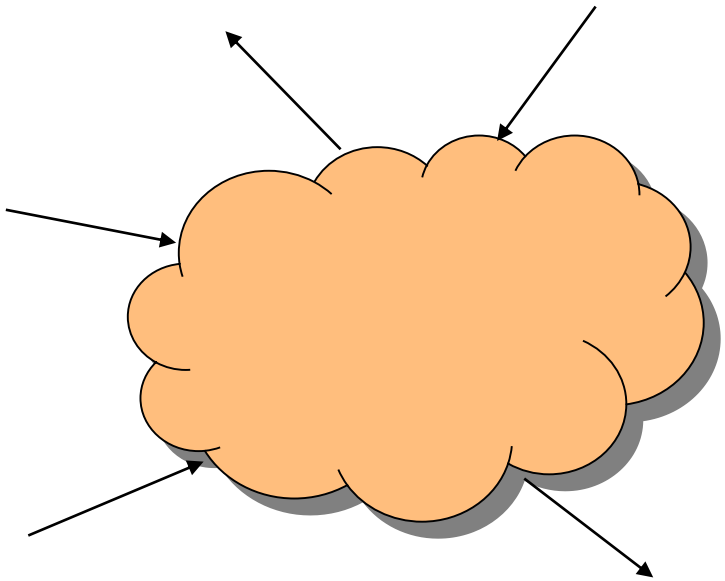
方差：$\sigma_t^2 = \frac{1}{(\mu c)^2}$

均方差：$\sigma_t = \frac{1}{\mu c}$

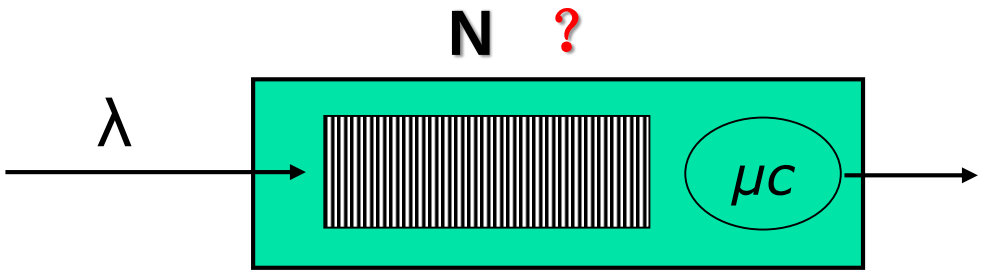
（1） Little 定律

设有一个封闭网络（节点）：

- 数据为长短不一的报文
- 报文随机地进入网络,再按其排队的先后顺序,发往其它地方



研究: 在稳定状态下，网络中暂存的报文数目N与哪些因素有关？关系如何？



——稳定状态下的数据流

Little定律：

在稳定状态下，存储在网络中的报文平均数，等于报文的平均到达率乘以这些报文在网络中经历的平均时间。

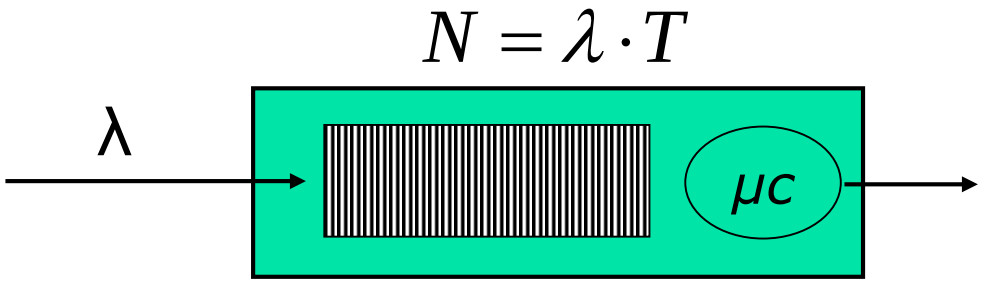
$$N = \lambda \cdot T$$

N ——网络中的平均报文数

T ——报文在网络中的平均逗留时间

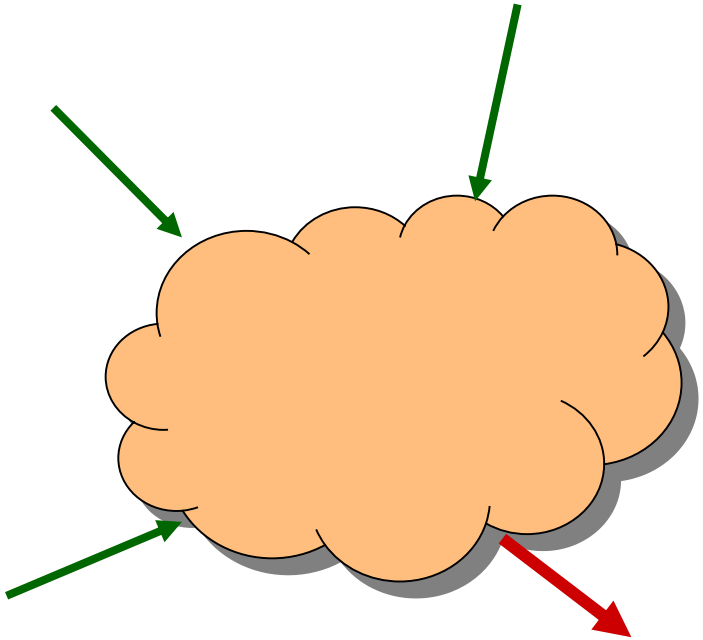
λ ——报文的平均到达率

Little定律对于任意设定边界的封闭网络，对任意分布的数据流都正确。



（2） 通信量强度（traffic intensity）——ρ

也称业务强度，表示网络的忙碌程度，信道忙的概率



假设：

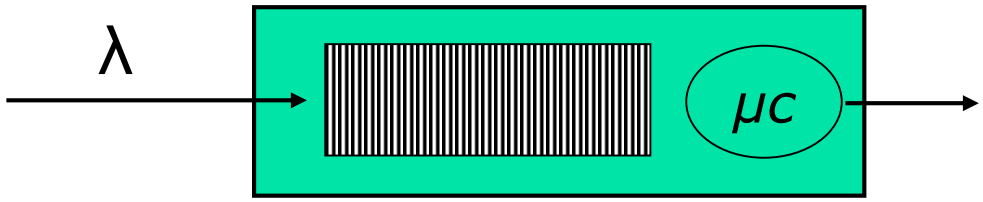
① 网络中有多个报文输入端，但只有一个输出信道

② 报文在队列中按先到先发的原则进行发送

目的：

从第i个报文M_i发完到第i+1个报文M_{i+1}发完时间内（t_i，t_{i+1}），网络中报文N的变化情况。

（2） 通信量强度（traffic intensity）——ρ



设报文的到达率为λ msg/s，链路传输速率为c bit/s，报文的平均长度 $\frac{1}{\mu}$ bits，每个报文发送的时间为：

$$\frac{1/\mu}{c}=\frac{1}{\mu c}$$

即链路输出率为μc msg/s

当网络内报文数>0时，输出率为μc

当网络内报文数=0时，输出率为0。

稳态时：

报文的平均输入率=平均输出率

即：

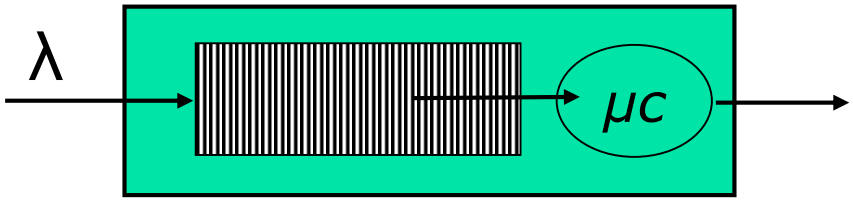
λ=ρ[输出信道忙]. μc + ρ[输出信道闲]. 0 = ρ. μc

$$\rho=\frac{\lambda}{\mu c} \qquad (0\le\rho<1)$$

——通信量强度

通信量强度ρ等于报文平均到达率与输出信道的平均输出率之比。 ρ越大，网络越忙碌

（2） 通信量强度（traffic intensity）——ρ



网络中的平均报文数N：

设一个报文的平均排队时间为w，每个报文发送时间为 $\frac{1}{\mu C}$ ，则该报文在系统中逗留时间为：

$$T = w + \frac{1}{\mu C}$$

两边乘以λ：

$$\lambda T = \lambda w + \frac{\lambda}{\mu C}$$

$$N = N_g + \rho$$

N——网络中的平均报文数

Ng——正在排队的平均报文数

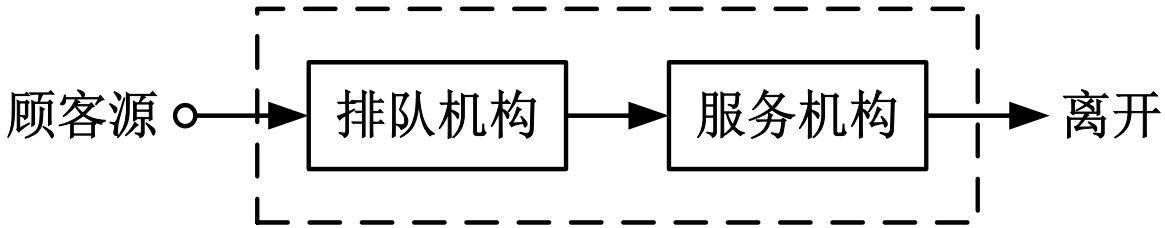
ρ——正在发送的平均报文数

（报文发送期间到达的报文数）

结论：网络中逗留的平均报文数等于正在排队等待的平均报文数与正在发送的平均报文数之和。

1．排队论基础 —— 排队模型

多个顾客要求一个或多个服务员为他们提供服务，即形成资源（服务员）共享系统。当服务员所能提供的服务时刻和速度不能满足顾客的瞬间需求时，必然形成排队现象。



（1） 排队模型的5大要素

① 顾客到达规律（A）：顾客（报文）到达时间间隔的概率分布

② 服务规律（B）：服务时间（报文发送时间）的长短服从的规律

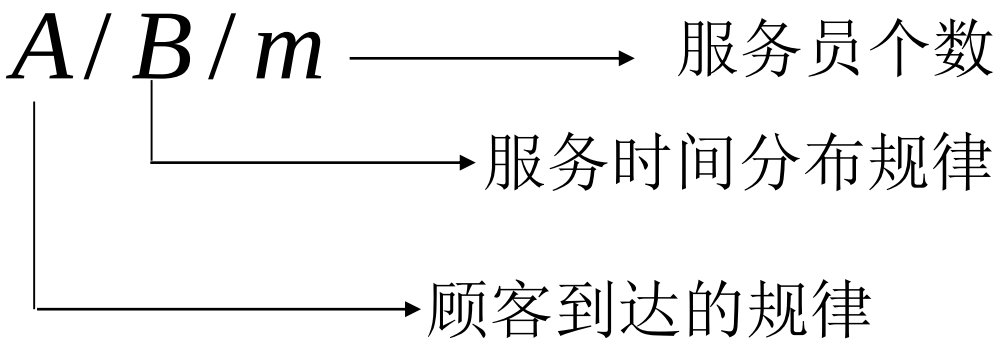
③ 服务员人数（m）：发送信道的数目

④ 排队法则：FIFO：First Input First Output

⑤ 队列空间限制（∞）

（1） 排队模型的5大要素

前三个要素是主要的，用两个字母和一个数字表示：

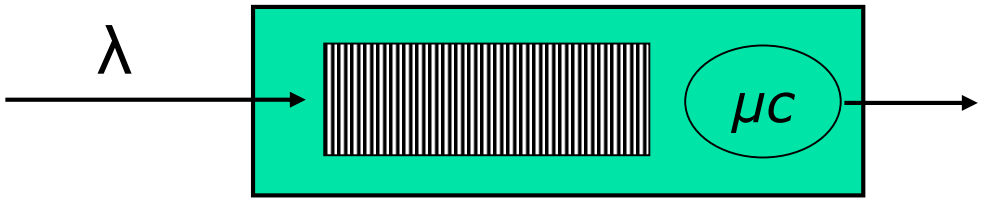


A、B的取值
- M：负指数概率分布（泊松分布）
- D：确定时间分布（均匀分布）
- G：任意分布

研究目的：

顾客在系统中的逗留时间（报文时延）和顾客数量（滞留报文数量）与系统参数之间的关系。

（2） M/M/1模型



λ：平均到达率　　μc：平均发送（输出）率

最关心的问题：

- **报文在信道中的平均等待时间T**
- **信道中滞留（等待）的平均报文数N**

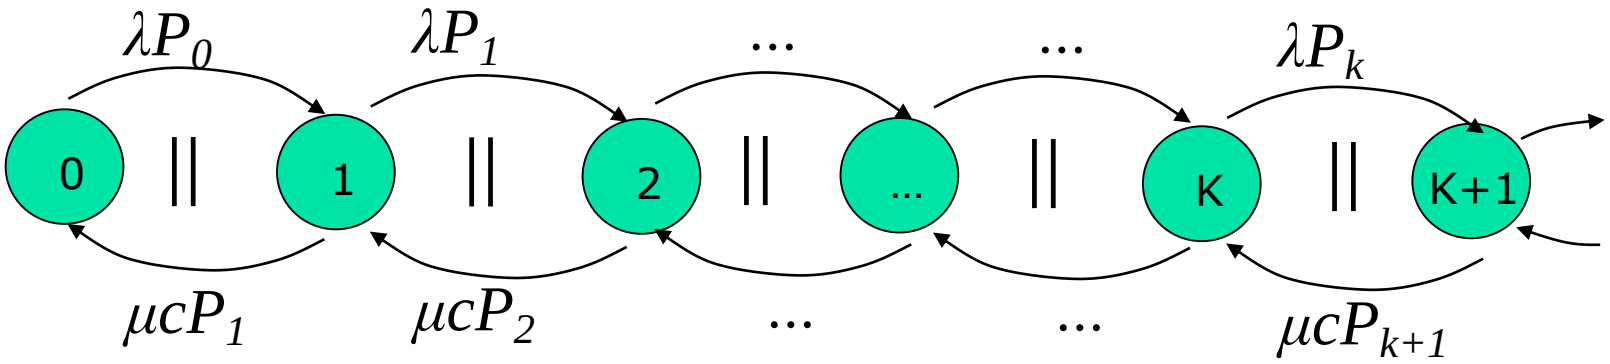
T＝平均发送时间+平均排队时间

N＝正在发送的报文数+平均队列长度（即排队的报文数）

（2） M/M/1模型

当M/M/1系统从初始状态开始运行足够长的时间后就进入平衡态，这时，系统处于k状态的概率为P_k 。

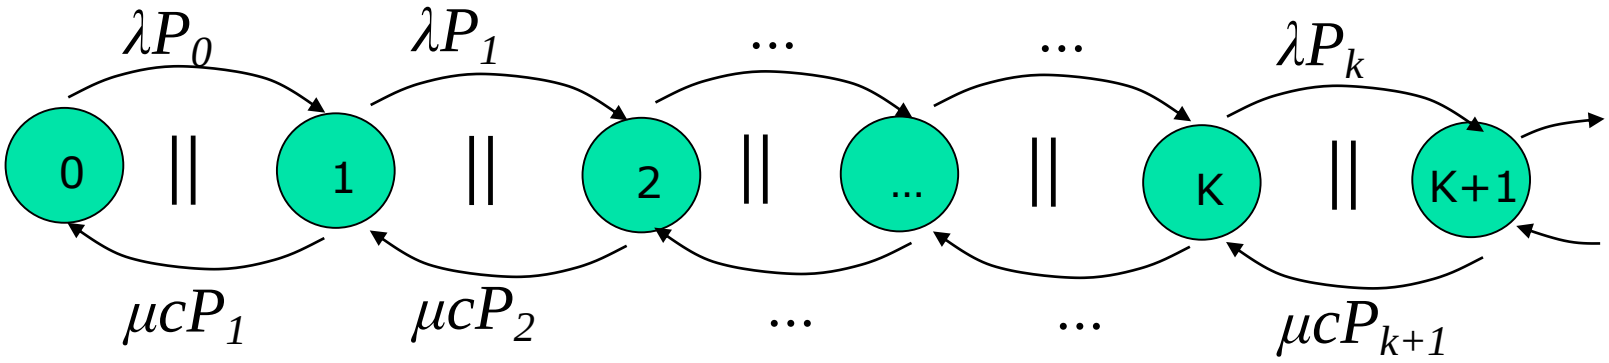
k状态：在时间间隔t内系统中有k 个报文



状态转换图

有向弧线上的数字表示单位时间内的平均转移率（即当状态转化发生时，有效到达或发送的报文数）。在平衡状态下，任何状态的转出数与转入数相等。即：

（2） M/M/1模型



对于0状态：$\lambda P_0 = \mu c P_1 \Rightarrow P_1 = \frac{\lambda}{\mu c} P_0 = \rho P_0$

对于1状态：$\lambda P_0 + \mu c P_2 = (\lambda + \mu c) P_1$

$$P_2 = \frac{(\lambda + \mu c) P_1 - \lambda P_0}{\mu c} = (\rho + 1)\rho P_0 - \lambda P_0 = \rho^2 P_0$$

同理：对于k状态：$P_k = \rho^k P_0$

（2） M/M/1模型

$$\because \rho < 1 \qquad \sum_{k=0}^{\infty} P_k = 1(\text{全概率})$$

$$\sum_{k=0}^{\infty} P_k = \sum_{k=0}^{\infty} \rho^k P_0 = P_0 \sum_{k=0}^{\infty} \rho^k = \frac{P_0}{1-\rho} = 1$$

$$\therefore P_0 = 1-\rho$$

$$\therefore \rho = 1 - P_0$$

（含义：**ρ**代表非空概率，即信道忙的概率）

$$\therefore P_k = \rho^k P_0 = \rho^k (1-\rho)$$

（2） M/M/1模型

系统中的平均报文数N：

$$N=\sum_{k=0}^{\infty}kP_k=\sum_{k=0}^{\infty}k\rho^k(1-\rho)=(1-\rho)\frac{\rho}{(1-\rho)^2}=\frac{\rho}{1-\rho}$$

系统的平均队列长度（排队等待的报文数）Ng：

$$N_g=N-\rho=\frac{\rho}{1-\rho}-\rho=\frac{\rho^2}{1-\rho}$$

平均等待时间（平均延迟时间）T：

根据Little定律：　$N=\lambda T$

（2） M/M/1模型

平均等待时间（平均延迟时间）T：

$$T=\frac{N}{\lambda}=\frac{\rho}{\lambda(1-\rho)}=\frac{\frac{\lambda}{\mu c}}{\lambda(1-\frac{\lambda}{\mu c})}=\frac{1}{\mu c-\lambda}$$

排队时间Tq：

$$T_q=T-\text{平均发送时间}=\mathrm{T}-\frac{1}{\mu c}=\frac{\lambda}{\mu c(\mu c-\lambda)}$$

（2） M/M/1模型

系统中的平均报文数N： $$N = \frac{\rho}{1-\rho}$$

系统的平均队列长度（排队等待的报文数）Ng： $$N_g = \frac{\rho^2}{1-\rho}$$

平均等待时间（平均延迟时间）T： $$T = \frac{1}{\mu c - \lambda}$$

排队时间Tq： $$T_q = \frac{\lambda}{\mu c(\mu c - \lambda)}$$

（3） M/G/1模型

$$N = \rho + \frac{\rho^2 + \lambda^2 \sigma_Y^2}{2(1-\rho)}$$

$$T = \frac{1}{\mu c} + \frac{\rho + \lambda \mu c \sigma_Y^2}{2\mu c(1-\rho)}$$

其中：

通信量强度 $\rho = \frac{\lambda}{\mu c}$

σ_Y^2： 服务时间的方差（报文发送时间的方差）

M/M/1 模型是M/G/1模型的特例（$\sigma_Y = 1/\mu c$）

结论： 网络中报文数的平均值以及报文时延的平均值取决于：

- **报文到达率** λ
- **报文发送时间平均值** $1/\mu c$
- **报文发送时间的方差** σ_Y^2

（4） M/D/1模型

每个报文的发送时间是固定的，即每个报文的长度是固定的。

$$\sigma_Y^2 = 0$$

$$N = \rho + \frac{\rho^2}{2(1-\rho)} = \frac{\rho(2-\rho)}{2(1-\rho)}$$

$$T = \frac{1}{\mu c} + \frac{\rho}{2\mu c(1-\rho)} = \frac{2-\rho}{2\mu c(1-\rho)}$$

对应于分组交换

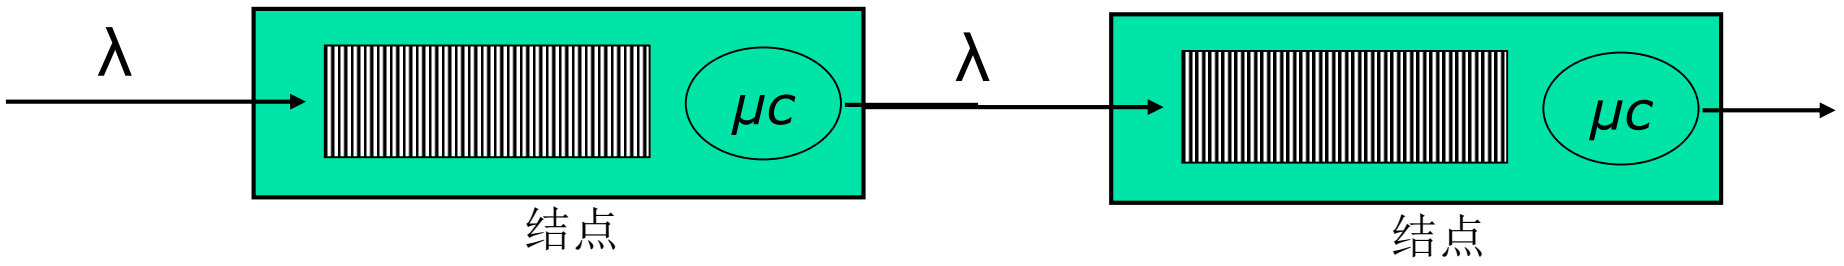
（4） M/D/1模型

$$\because N_M - N_D = \frac{\rho}{(1-\rho)} - \frac{\rho(2-\rho)}{2(1-\rho)} = \frac{\rho^2}{2(1-\rho)} > 0$$

即M/M/1模型系统中的报文数多于M/D/1模型，说明分组交换M/D/1模型优于M/M/1模型。

2. 排队论基础 ——网络平均延迟时间分析

（1） 一个分组经过一个信道的平均延迟时间（考虑M/M/1模型）



一个分组到达某一结点，在其中存储、排队，等待在信道上输出的平均延迟时间为：

$$T = \frac{1}{\mu C - \lambda}$$

其中：

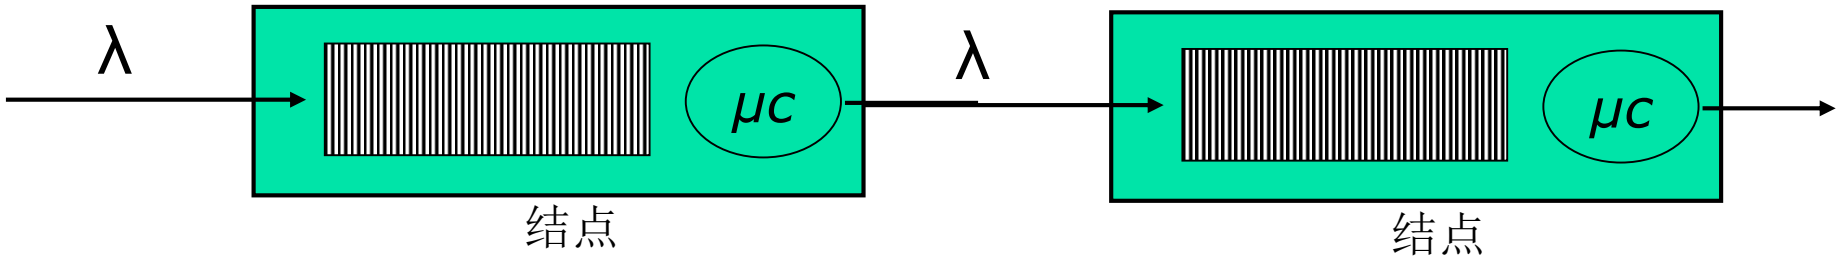
$1/\mu$：平均分组长度(比特/分组)

C：信道容量（链路传输速率）(比特/秒)

λ：分组平均到达率（链路中的信息量）(分组/秒)

2. 排队论基础 ——网络平均延迟时间分析

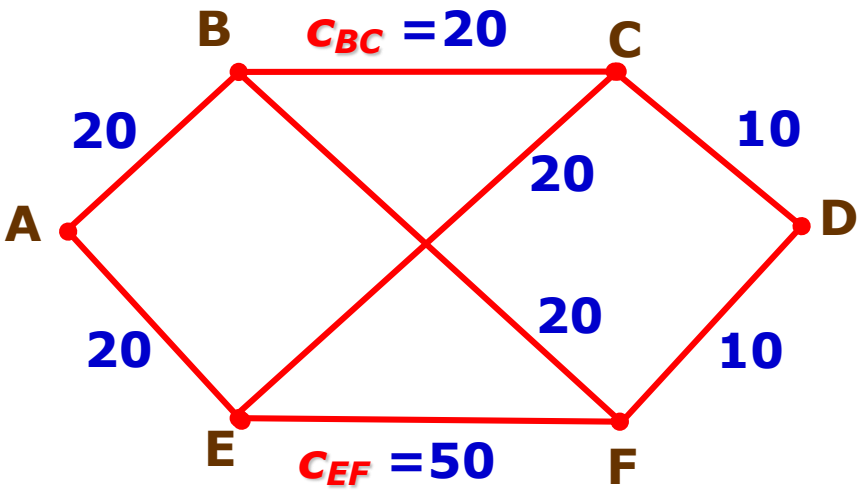
（1） 一个分组经过一个信道的平均延迟时间（考虑M/M/1模型）



例： 网络中某结点的平均分组长度$1/\mu$=1000bit/分组，信道容量c=10kbps，分组平均到达率λ=5分组/秒。求分组经过该结点的平均延迟时间。

$$T=\frac{1}{\mu c-\lambda}=\frac{1}{\frac{1}{1000}\cdot 10\times 10^{3}-5}=0.2s$$

（2） 网络的平均延迟时间（考虑M/M/1模型）

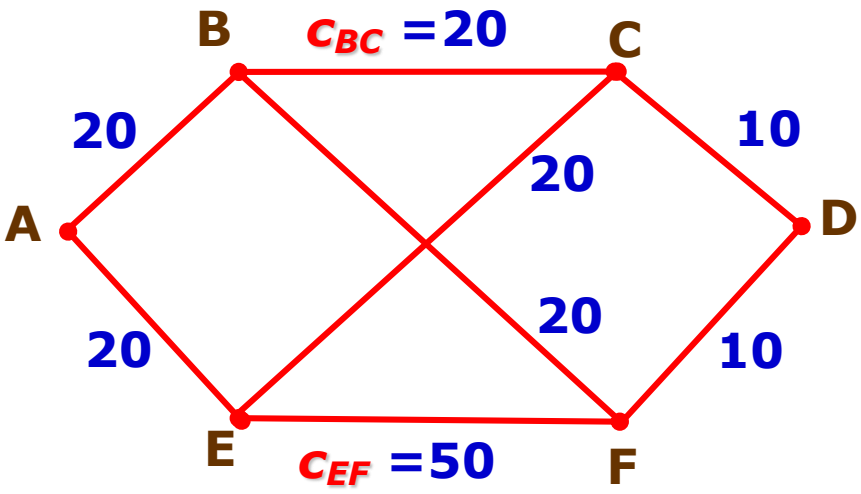


	A	B	C	D	E	F
A		9 AB	4 ABC	1 ABFD	7 AE	4 AEF
B	9 BA		8 BC	3 BFD	2 BFE	4 BF
C	4 CBA	8 CB		3 CD	3 CE	2 CEF
D	1 DFBA	3 DFB	3 DC		3 DCE	4 DF
E	7 EA	2 EFB	3 EC	3 ECD		5 EF
F	4 FEA	4 FB	2 FEC	4 FD	5 FE	

例：某网络由6结点8条信道组成，每个信道的容量为c_i kbps，双向对称，分组平均长度$1/\mu$=800bit/分组，结点间端对端平均信息量为r_{ij}分组/秒（i,j=1,2,…6），路径分配见上表，双向对称。求一个分组通过网络的平均时延 $\overline{T}$

2. 排队论基础 ——网络平均延迟时间分析

（2） 网络的平均延迟时间（考虑M/M/1模型）



	A	B	C	D	E	F
A		9 AB	4 ABC	1 ABFD	7 AE	4 AEF
B	9 BA		8 BC	3 BFD	2 BFE	4 BF
C	4 CBA	8 CB		3 CD	3 CE	2 CEF
D	1 DFBA	3 DFB	3 DC		3 DCE	4 DF
E	7 EA	2 EFB	3 EC	3 ECD		5 EF
F	4 FEA	4 FB	2 FEC	4 FD	5 FE	

分析： 分组通过通信子网可能经若干段存储转发。

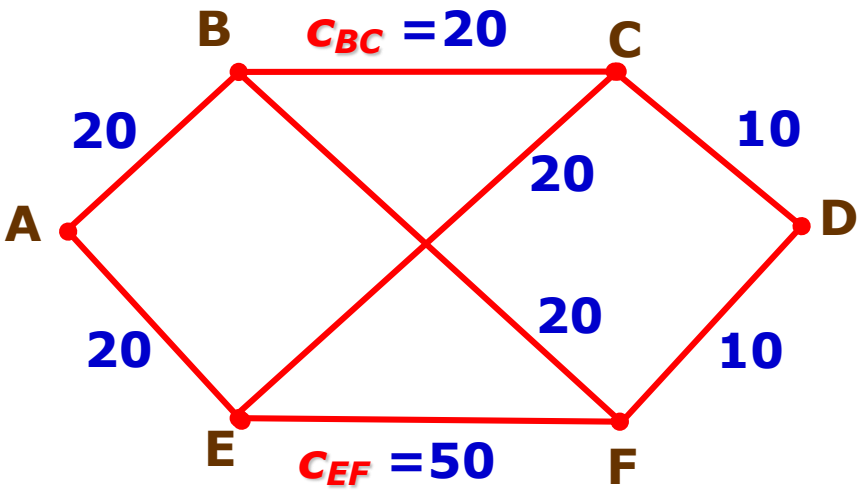
每个信道容量和信息量不同

分组通过子网的路径不同，经过的段数不同

→ 每个分组的延迟不同

——网络平均延迟时间分析

（2） 网络的平均延迟时间（考虑M/M/1模型）



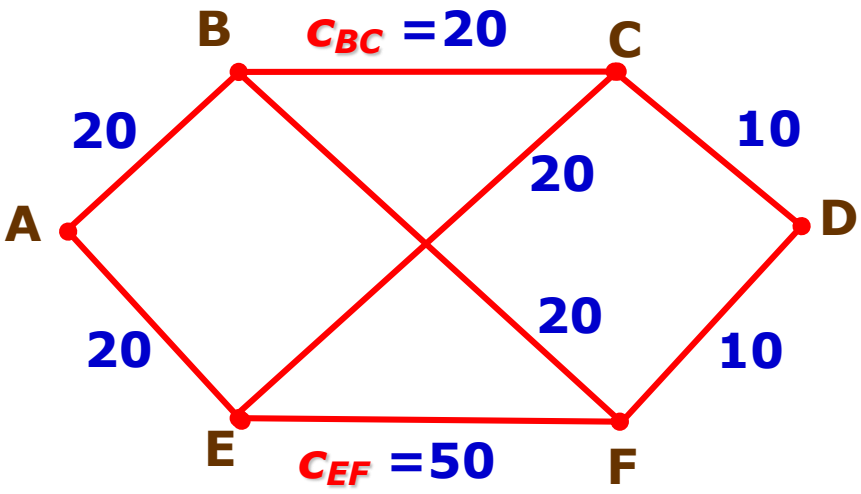
	A	B	C	D	E	F
A		9 AB	4 ABC	1 ABFD	7 AE	4 AEF
B	9 BA		8 BC	3 BFD	2 BFE	4 BF
C	4 CBA	8 CB		3 CD	3 CE	2 CEF
D	1 DFBA	3 DFB	3 DC		3 DCE	4 DF
E	7 EA	2 EFB	3 EC	3 ECD		5 EF
F	4 FEA	4 FB	2 FEC	4 FD	5 FE	

分析：

一个分组通过网络的平均延迟时间 $\overline{T}$ = 一个分组通过网络时平均走过的段数 $\overline{n}$ × 一个分组通过网络中每段的平均延迟时间 T'

$$\overline{T} = \overline{n} \times T'$$

（2） 网络的平均延迟时间（考虑M/M/1模型）



	A	B	C	D	E	F
A		9 AB	4 ABC	1 ABFD	7 AE	4 AEF
B	9 BA		8 BC	3 BFD	2 BFE	4 BF
C	4 CBA	8 CB		3 CD	3 CE	2 CEF
D	1 DFBA	3 DFB	3 DC		3 DCE	4 DF
E	7 EA	2 EFB	3 EC	3 ECD		5 EF
F	4 FEA	4 FB	2 FEC	4 FD	5 FE	

每条信道的平均信息量λ_i：

$$\lambda_{AB} = \gamma_{AB} + \gamma_{AC} + \gamma_{AD} = 9 + 4 + 1 = 14$$

$$\lambda_{BF} = \gamma_{AD} + \gamma_{BD} + \gamma_{BE} + \gamma_{BF} = 1 + 3 + 2 + 4 = 10$$

（2） 网络的平均延迟时间（考虑M/M/1模型）

每条信道的平均信息量λ_i：

$$\lambda_{AB}=\gamma_{AB}+\gamma_{AC}+\gamma_{AD}=9+4+1=14$$

$$\lambda_{BF}=\gamma_{AD}+\gamma_{BD}+\gamma_{BE}+\gamma_{BF}=1+3+2+4=10$$

$$\lambda_{EF}=\gamma_{AF}+\gamma_{CF}+\gamma_{EF}+\gamma_{EB}=4+2+5+2=13$$

$$\lambda_{BC}=\gamma_{AC}+\gamma_{BC}=4+8=12$$

$$\lambda_{CD}=\gamma_{CD}+\gamma_{ED}=3+3=6$$

$$\lambda_{AE}=\gamma_{AE}+\gamma_{AF}=7+4=11$$

$$\lambda_{FD}=\gamma_{AD}+\gamma_{BD}+\gamma_{FD}=1+3+4=8$$

$$\lambda_{EC}=\gamma_{EC}+\gamma_{FC}+\gamma_{ED}=3+2+3=8$$

（2） 网络的平均延迟时间（考虑M/M/1模型）

每条信道的平均延迟时间T_i

i	信道	λ_i (分组/s)	c_i (kbps)	μc_i (分组/s)	$T_i=1/(\mu c_i-\lambda_i)$ (ms)
1	AB	14	20	25	91
2	BC	12	20	25	77
3	CD	6	10	12.5	154
4	AE	11	20	25	71
5	EF	13	50	62.5	20
6	FD	8	10	12.5	222
7	BF	10	20	25	57
8	EC	8	20	25	59

（2） 网络的平均延迟时间（考虑M/M/1模型）

一个分组通过网络中每段的平均延迟时间T′

$$T' = \frac{\sum_{i=1}^{m}(\lambda_i T_i)}{\sum_{i=1}^{m}\lambda_i} = \sum_{i=1}^{m}\left(\frac{\lambda_i}{\lambda}T_i\right) = 86ms$$

——以λ_i为权系数的加权平均。

一个分组通过网络时平均走过的段数 $\overline{n}$

$\lambda = \sum_{i=1}^{m}\lambda_i = 82$ 网络中所有信道信息量的总和

$\gamma = \sum_{i=1}^{n}\sum_{j=1}^{n}\gamma_{ij} = 62$ 所有端对端信息量的总和

由于对称性，只累加了一半

$$\overline{n} = \frac{\lambda}{\gamma} = 1.32$$

（2） 网络的平均延迟时间（考虑M/M/1模型）

一个分组通过网络的平均延迟时间 $\overline{T}$

$$\therefore \quad \overline{T} = \overline{n} \cdot T' = \frac{\lambda}{\gamma} \cdot \sum_{i=1}^{m} \left(\frac{\lambda_i}{\lambda} T_i \right)$$

$$= \frac{1}{\gamma} \sum_{i=1}^{m} \frac{\lambda_i}{\mu C_i - \lambda_i} = 1.32 \times 86 \approx 114\, ms$$

分析： 若所有γ_{ij}皆乘以一个系数k, 则

$$\overline{T} = \frac{1}{k\gamma} \sum_{i=1}^{m} \frac{k\lambda_i}{\mu C_i - k\lambda_i} = \frac{1}{\gamma} \sum_{i=1}^{m} \frac{\lambda_i}{\mu C_i - k\lambda_i}$$

——相当于增加或减少网络中的信息量。

（2） 网络的平均延迟时间（考虑M/M/1模型）

分析：

$$\bar{T} = \frac{1}{\gamma}\sum_{i=1}^{m}\frac{\lambda_i}{\mu c_i - k\lambda_i}$$

—— 将$\bar{T}$视为k的函数。即$\bar{T}(k)$

$\therefore\ k \uparrow \quad \rightarrow \quad \bar{T} \uparrow$

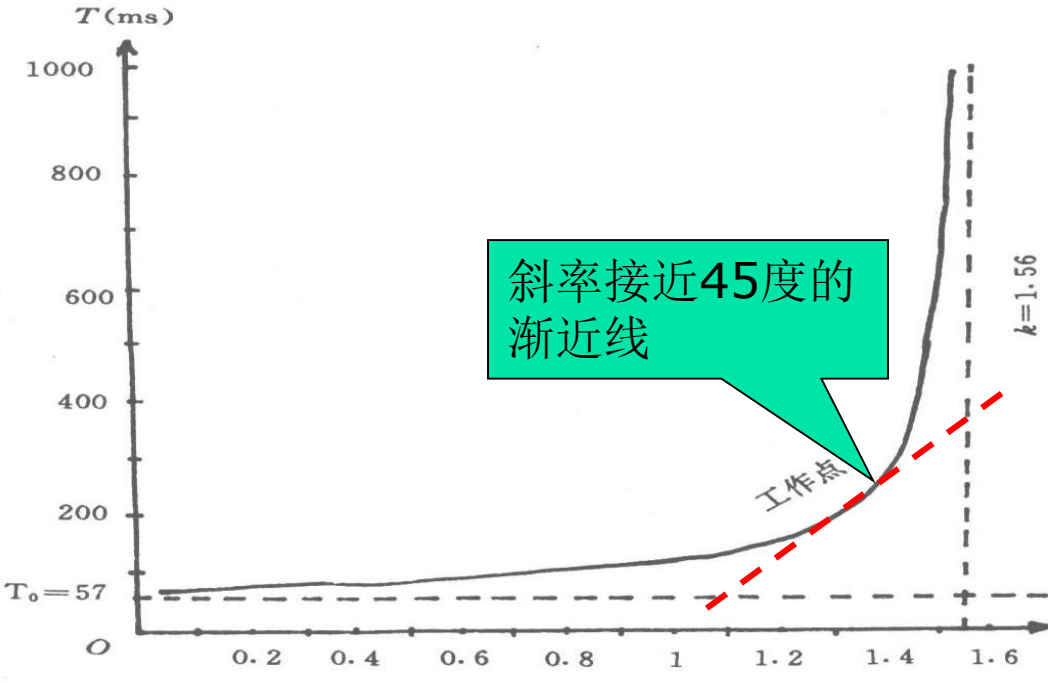
当$k \rightarrow 0$ 时

$$\bar{T} \rightarrow \frac{1}{\gamma}\sum_{i=1}^{m}\frac{\lambda_i}{\mu c_i} = \bar{T}_0 \approx 57ms$$

水平渐进线

当k趋近于 $\min\limits_{1\le i\le m}\dfrac{\mu c_i}{\lambda_i}$ 时，

$\bar{T} \quad \rightarrow \quad \infty$, 垂直渐进线



结论：网络工作时，我们希望k越大越好，T越小越好，但这两个指标是互相制约的。折衷的办法是：工作点取曲线斜率接近45度的渐近线的地方，它既有较短的延时，又有较大的吞吐量。